



中山大學

SUN YAT-SEN UNIVERSITY

并程序设计与算法实验

Lab11-CUDA 卷积计算

姓 名 _____ 林思涵

学 号 _____ 23336142

学 院 _____ 计算机学院

专 业 _____ 计算机科学与技术

2026 年 6 月 17 日

1 实验目的

- 理解神经网络中二维卷积的基本计算过程，以及 stride 和 padding 对输出尺寸与计算量的影响。
- 掌握 CUDA 直接卷积（滑窗法）的实现方法，理解线程块配置、任务映射和访存方式对性能的影响。
- 掌握 im2col 方法，将卷积转换为矩阵乘法并使用已有的 CUDA 矩阵乘法程序完成计算。
- 学习使用 cuDNN 卷积接口，对比直接卷积、im2col 方法和 cuDNN 的运行性能。

2 实验内容

本实验实现神经网络中的二维卷积操作。卷积核不进行翻转，不考虑偏置项，bias 设置为 0。为保证不同实现之间能够公平比较，统一采用以下实验设置：

- 输入为 $N \times N \times 3$ 的单精度数据，batch size 为 1；
- 使用一个 $3 \times 3 \times 3$ 卷积核，输出通道数为 1；
- padding 设置为 1，stride 分别设置为 1、2 和 3；
- 根据实验设备，从 32×32 至 512×512 ，或从 256×256 至 4096×4096 中选择不小于三组输入规模；三种实现采用相同的输入和卷积参数。

输出尺寸计算公式为：

$$N_{\text{out}} = \left\lfloor \frac{N + 2P - K}{S} \right\rfloor + 1.$$

其中， P 、 K 和 S 分别表示 padding、卷积核大小和 stride。

2.1 CUDA 直接卷积

使用 CUDA 实现直接卷积（滑窗法），由 CUDA 线程计算各个输出位置的卷积结果。测试不同输入图像大小、stride 和线程块大小下的运行时间；自行设计并说明输出任务到 CUDA 线程的映射方式，至少比较两种不同的任务粒度或线程映射方式。这里比较的是线程任务映射方式，而不是不同的卷积算法。

2.2 im2col 方法

使用 im2col 将各个滑动窗口展开为矩阵，将卷积核展开为向量，再使用已有的 CUDA 矩阵乘法程序完成卷积计算。矩阵乘法程序应支持 im2col 产生的矩形矩阵。测试不同输入图像大小和 stride 下 im2col 方法的运行时间。

2.3 cuDNN 卷积

使用 cuDNN 提供的卷积接口完成相同的卷积操作，并与直接卷积和 im2col 方法进行性能比较。三种实现只统计 GPU 计算阶段：直接卷积统计卷积 kernel 时间，im2col 方法统计数据展开与矩阵乘法的总时间，cuDNN 统计卷积执行时间；不包含显存申请、程序初始化和主机与设备之间的数据传输时间。每组实验预热后重复执行多次并取平均值。

3 实验结果

本节记录以下性能数据。输入规模和线程块大小可根据实验设备调整，但每组实验只改变所考察的变量，其余参数保持一致。

3.1 线程块大小对直接卷积性能的影响

固定输入图像大小、stride 和任务映射方式，测量不同线程块大小下 CUDA 直接卷积的运行时间。

表 1: 不同线程块大小下 CUDA 直接卷积的运行时间 (ms)

输入图像大小	线程块大小	运行时间
$N \times N$	8×8	
	16×16	
	32×32	

3.2 任务划分与线程映射方式对性能的影响

固定输入图像大小、stride 和线程块线程数，测量不同任务划分与线程映射方式下直接卷积的运行时间，并简要说明每个线程负责的计算任务。

表 2: 不同任务划分与线程映射方式下直接卷积的运行时间 (ms)

编号	任务划分与线程映射方式	运行时间
方式一		
方式二		
方式三 (可选)		

3.3 不同卷积实现的性能对比

在相同输入图像大小、stride、padding 和卷积核设置下，测量直接卷积、im2col 方法和 cuDNN 的运行时间。该表同时用于观察输入规模和 stride 对三种实现性能的影响。

表 3: 不同卷积实现的性能对比 (时间单位: ms)

输入图像大小	stride	直接卷积	im2col 方法	cuDNN
$N_1 \times N_1$	1			
	2			
	3			
$N_2 \times N_2$	1			
	2			
	3			
$N_3 \times N_3$	1			
	2			
	3			

4 实验分析

根据实验结果完成以下分析:

1. 分析输入图像大小、stride 和线程块大小对直接卷积运行时间的影响; 说明哪种线程块配置性能较好, 并结合并行度和硬件资源使用分析原因。

回答:

2. 说明所采用的任务划分与线程映射方式, 分析不同方式对任务粒度、负载均衡和全局内存访问的影响。

回答:

3. 对比直接卷积与 im2col 方法的性能, 分析 im2col 的数据展开与额外内存访问开销, 以及规则矩阵乘法可能带来的收益。

回答:

4. 对比自行实现的卷积与 cuDNN 的性能; 如果性能低于 cuDNN, 结合数据复用、合并访存、共享内存、常量内存和线程块配置说明可能的改进方向。

回答:

A 运行命令

以下命令默认在 Lab11 目录下执行。

```
make clean all CUDNN=1
```

```
./build/convolution 256 3 1 16 5 \  
> results/convolution_single_256_s1.txt
```

```
./build/convolution --benchmark 5 \  
> results/convolution_benchmark.csv
```